



Redes bayesianas gaussianas con estructura elicitada por estudiantes de medicina: dependencias entre biomarcadores en enfermedad renal crónica

Juan Pedro Enríquez Ruiz Velasco¹, Angelo Dayvis Farfán Torres², Pablo Emiliano González Ríos³
and Eduardo Medina Meza⁴

¹ Instituto Tecnológico de Estudios Superiores de Monterrey (ITESM), Departamento de Ingeniería y Ciencias, Jalisco, México

Fecha de publicación: 30/08/2026

Abstract— Las redes bayesianas gaussianas (GBN) permiten representar de forma interpretable las dependencias entre biomarcadores clínicos. Este trabajo aplica GBN a nueve variables continuas del conjunto *Chronic Kidney Disease* de UCI ($n = 218$ tras depuración) con estructuras elicitadas de estudiantes de medicina, comparadas contra una estructura aprendida por *hill-climbing* mediante BIC y AIC. Se evaluó además una alternativa no paramétrica basada en regresión de Nadaraya–Watson con criterios de información corregidos por grados de libertad efectivos, y se incorporó el indicador de diabetes mediante una red gaussiana condicional. La estructura aprendida supera a las elicitadas por 228 puntos de BIC pero contiene arcos causalmente imposibles; el modelo no paramétrico es preferido por AIC y rechazado por BIC; y la variable categórica mejora el BIC en 89.9 puntos, aunque solo como nodo padre. De seis consultas clínicas, cuatro resultaron irresolubles por referirse al diagnóstico, que la familia de modelos no puede expresar como descendiente de variables continuas. Se concluye que una GBN de biomarcadores describe bien su estructura pero es inadecuada para preguntas diagnósticas, y se propone un clasificador *naive Bayes* gaussiano como extensión natural.

Keywords— redes bayesianas gaussianas; enfermedad renal crónica; elicitación de estructura; regresión de Nadaraya–Watson; redes gaussianas condicionales; criterios de información

I. INTRODUCCIÓN

La Enfermedad Renal Crónica (ERC) afecta a millones de personas a nivel global y puede derivar en distintas complicaciones, como retención de líquidos, alteraciones electrolíticas, anemia, complicaciones cardiovasculares y daño renal terminal, entre otras. Dado que muchas de estas complicaciones pueden prevenirse o retrasarse si la enfermedad se detecta a tiempo, resulta fundamental contar con herramientas que ayuden a identificar patrones de riesgo antes de que el daño renal sea severo.

En este trabajo exploramos cómo las Redes Bayesianas Gaussianas pueden ser una herramienta útil para representar y comprender las relaciones entre los distintos biomarcadores asociados a la ERC, con el objetivo de apoyar su detección y prevención temprana. A diferencia de otros modelos estadísticos, las redes bayesianas permiten representar de forma gráfica e interpretable cómo un biomarcador puede influir o depender de otros, lo cual resulta especialmente valioso en un contexto clínico, donde entender el “por qué” detrás de una relación es tan importante como predecir un resultado.

Sin embargo, definir correctamente estas relaciones no es una tarea trivial, ya que requiere conocimiento clínico especializado. Por ello, antes de construir nuestro modelo, decidimos apoyarnos en el conocimiento de personas que ya están inmersas en el área de la salud. Visitamos la Escuela de Medicina del campus y entrevistamos a cinco estudiantes avanzados de medicina con conocimiento sobre la ERC, a quienes les pedimos que, con base en su experiencia, propusieran un Grafo Acíclico Dirigido (DAG) que representara cómo creían que se relacionaban los biomarcadores relevantes para esta enfermedad. Como resultado, obtuvimos tres estructuras distintas, cada una reflejando una perspectiva particular sobre estas dependencias. Adicionalmente, cada estudiante propuso al menos dos preguntas (*queries*) clínicamente relevantes que podrían responderse utilizando un modelo de este tipo, las cuales utilizamos más adelante para evaluar la utilidad práctica de nuestras redes.

De esta manera, buscamos combinar el conocimiento experto de personas cercanas a la práctica médica con el poder de las redes bayesianas gaussianas, para construir un modelo que no solo sea estadísticamente robusto, sino también clínicamente interpretable y útil.

II. METODOLOGÍA

a. Datos

Se trabajó con el conjunto *Chronic Kidney Disease* del repositorio UCI Machine Learning [1]. Contiene 400 registros de pacientes con y sin diagnóstico de ERC y 25 variables clínicas. De ellas, once son numéricas continuas: edad (*age*), presión arterial (*bp*), glucosa aleatoria en sangre (*bgr*), urea en sangre (*bu*), creatinina sérica (*sc*), sodio (*sod*), potasio (*pot*), hemoglobina (*hemo*), volumen celular aglomerado (*pvc*), conteo de leucocitos (*wc*) y conteo de eritrocitos (*rc*). Las catorce restantes son categóricas, como la presencia de hipertensión o de diabetes, y no pueden representarse directamente en una red gaussiana, por lo que quedaron fuera del modelo principal.

Tres de las variables continuas, la hemoglobina, el volumen celular aglomerado y el conteo de eritrocitos, miden aspectos muy cercanos de la misma condición hematológica, como señaló una de las personas entrevistadas. Incluir las tres aportaría poca información adicional y complicaría la estimación. Se conservó únicamente la hemoglobina, que es la que tiene menos datos faltantes. El modelo quedó así con nueve variables.

b. Elicitación de estructuras

Una red bayesiana necesita una estructura: un grafo que indique qué variables dependen de cuáles. Los datos por sí solos no la determinan de forma única, así que se recurrió a conocimiento clínico. Se entrevistó a cinco estudiantes avanzados de la Escuela de Medicina del campus. Se les mostró la lista de variables disponibles y se les pidió dibujar un grafo acíclico dirigido (DAG) con las relaciones de dependencia que consideraran plausibles, algunos trabajando de forma individual y otros en pareja. También se les pidió al menos dos preguntas clínicas que un modelo de este tipo debería poder responder. El procedimiento produjo tres estructuras distintas y seis consultas.

c. Redes bayesianas gaussianas

Una red bayesiana representa la distribución conjunta de un vector aleatorio $\mathbf{X} = (X_1, \dots, X_p)$ mediante un DAG $\mathcal{G}$ y un conjunto de distribuciones condicionales Θ . Cada variable depende únicamente de sus padres en el grafo, de modo que la densidad conjunta se descompone en un producto de términos locales:

$$f(x_1, \dots, x_p) = \prod_{j=1}^p f(x_j \mid \text{pa}(x_j)), \quad (1)$$

donde $\text{pa}(x_j)$ denota los valores de los padres de X_j .

En una *red bayesiana gaussiana* (GBN) se supone además que $\mathbf{X}$ sigue una distribución normal multivariada. Esto equivale a que cada variable sea una función lineal de sus padres más un error normal de varianza constante:

$$X_j \mid \text{Pa}(X_j) \sim \mathcal{N}\left(\beta_{j0} + \sum_{k \in \text{Pa}(j)} \beta_{jk} X_k, \sigma_j^2\right). \quad (2)$$



En la práctica, ajustar una GBN consiste en estimar una regresión lineal por cada nodo, tomando como predictores a sus padres. Se utilizó la función `bn.fit` del paquete `bnlearn` [2].

d. Criterios de información

Para decidir qué estructura describe mejor los datos se usaron el criterio de información bayesiano (BIC) y el de Akaike (AIC). Ambos premian el ajuste, medido por la log-verosimilitud ℓ , y castigan la complejidad, medida por el número de parámetros k :

$$\text{BIC}(\mathcal{G} \mid \mathcal{D}) = \sum_{j=1}^p \left[\ell_j - \frac{\log n}{2} k_j \right], \quad (3)$$

$$\text{AIC}(\mathcal{G} \mid \mathcal{D}) = \sum_{j=1}^p [\ell_j - k_j], \quad (4)$$

donde n es el número de observaciones y $k_j = |\text{Pa}(j)| + 2$ cuenta el intercepto, un coeficiente por padre y la desviación estándar del error. Con esta convención, **el mejor modelo es el de mayor puntuación**.

Cuando el error es gaussiano, la log-verosimilitud de un nodo se obtiene directamente de sus residuales:

$$\ell_j = -\frac{n}{2} \left[\log(2\pi) + \log\left(\frac{\text{RSS}_j}{n}\right) + 1 \right], \quad (5)$$

con RSS_j la suma de cuadrados residuales del nodo. Esta fórmula es la que permite comparar en igualdad de condiciones el modelo lineal con el no paramétrico que se describe más adelante.

e. Estructura de referencia

Además de las tres estructuras elicadas se aprendió una directamente de los datos con el algoritmo *hill-climbing*. Este parte de un grafo sin arcos y va agregando, quitando o invirtiendo uno a la vez mientras el BIC mejora. Sirve como punto de comparación, con una salvedad importante: como se eligió maximizando el BIC sobre los mismos datos con los que luego se evalúa, su puntuación está inflada y no es justo compararla directamente con las estructuras elicadas.

f. Alternativa no paramétrica

La GBN asume que la relación entre cada variable y sus padres es lineal. Para comprobar si ese supuesto es demasiado restrictivo se reemplazó cada regresión lineal por un estimador de Nadaraya–Watson [4, 5]. En lugar de ajustar una recta, este método estima la media condicional en cada punto como un promedio ponderado de las observaciones cercanas, donde las más próximas pesan más:

$$\hat{m}_{\mathbf{h}}(x) = \frac{\sum_{i=1}^n K_{\mathbf{h}}(x - \mathbf{X}_i) Y_i}{\sum_{i=1}^n K_{\mathbf{h}}(x - \mathbf{X}_i)}, \quad K_{\mathbf{h}}(\mathbf{u}) = \prod_{d=1}^q \frac{1}{h_d} K\left(\frac{u_d}{h_d}\right), \quad (6)$$

donde K es el núcleo gaussiano estándar, q es el número de padres del nodo y h_d controla qué tan cerca debe estar una observación para influir en la estimación. Se usó un ancho de banda distinto por predictor, fijado con la regla de Silverman ajustada a la dimensión, $h_d = 1.06 \hat{\sigma}_d n^{-1/(q+4)}$ [6].

Para calcular el BIC y el AIC de este modelo hace falta un equivalente al número de parámetros, que aquí no existe como tal. Se recurrió a los *grados de libertad efectivos* [7, 8]. Como el estimador es lineal en los datos, es decir $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$ para cierta matriz de suavizado $\mathbf{S}$, la traza de esa matriz mide cuánta flexibilidad tiene el modelo; en el caso de una regresión lineal coincide exactamente con el número de coeficientes. Así, para los nodos no paramétricos se usó $k_j = \text{tr}(\mathbf{S}_j) + 1$, sumando uno por la varianza del error, igual que en el caso lineal.

Para que la comparación fuera justa se cuidaron tres cosas: usar la log-verosimilitud completa de (5), incluidas las constantes que suelen omitirse cuando solo se comparan modelos no paramétricos entre sí; mantener la misma convención de signo y de penalización que en (3) y (4); y sumar todos los nodos de la red, incluidos los que no tienen padres.

g. Incorporación de variables categóricas

Las redes gaussianas condicionales (CLG) [3] permiten mezclar variables discretas y continuas. La idea es que, para cada combinación de valores de las variables discretas, existe una distribución normal distinta sobre las continuas. Esto trae una restricción importante: una variable discreta puede ser padre de una continua, pero no al revés.

Para este problema la consecuencia es directa. Un arco como $\text{dm} \rightarrow \text{bgr}$, que representa que la diabetes altera la glucosa, se puede modelar sin dificultad. En cambio, un arco que haga del diagnóstico de ERC un hijo de los biomarcadores continuos, que es la dirección clínicamente natural, no cabe en esta familia. Para medir cuánto aporta una variable categórica se ajustaron dos CLG idénticas salvo por la presencia del arco $\text{dm} \rightarrow \text{bgr}$, y se compararon con las versiones de BIC y AIC para datos mixtos.

III. APLICACIÓN

a. Preprocesamiento

Del conjunto original de 400 registros se retuvieron las nueve variables continuas descritas en la metodología. Retomando la redundancia entre `hemo`, `pcv` y `rc` antes mencionada se decide quedarse con `hemo` porque es la que menor proporción de datos faltantes (52 frente a 71 y 131 respectivamente).

La inspección de valores faltantes reveló que ninguna variable estaba completa y que los faltantes se distribuían a lo largo de todo el conjunto, por lo que la eliminación de registros incompletos redujo la muestra de 400 a 221 observaciones y se concluyó que una imputación por k-nn no es opción ya que se estarían inventando perfiles clínicos.

Adicionalmente se depuraron registros con valores fisiológicamente imposibles. El potasio sérico presentó un registro con valor de 47 mEq/L, cuando el rango compatible con la vida no excede aproximadamente 10 mEq/L; el sodio no presentó valores fuera del intervalo [110, 170] mEq/L.

Un caso que merece mención aparte es la presión arterial. La variable `bp` toma únicamente siete valores distintos, todos múltiplos de diez, por lo que difícilmente satisface el supuesto de continuidad que requiere una GBN. Bajo el mismo criterio de plausibilidad se descartaron los registros con 140 y 180 mmHg, incompatibles con una lectura diastólica. Se optó por conservar la variable, pese a su carácter casi discreto, dado que las personas entrevistadas le asignaron un papel central. Tras la depuración por implausibilidad se eliminaron tres registros, quedando una muestra final de 218 observaciones.

b. Análisis exploratorio

La Figura 1 presenta las distribuciones marginales de las nueve variables junto con la densidad normal ajustada, y la Figura 2 los gráficos cuantil-cuantil correspondientes.




Fig. 1: Distribuciones marginales de las nueve variables continuas. La línea punteada corresponde a la densidad normal ajustada por máxima verosimilitud.




Fig. 2: Gráficos cuantil-cuantil normales por variable.

La lectura conjunta de ambas figuras permite distinguir tres mecanismos de desviación. La edad y la hemoglobina se ajustan razonablemente a la densidad normal y sus cuantiles siguen la recta de referencia casi en toda su extensión: son las únicas dos variables para las que el supuesto resulta defendible. Un segundo grupo, formado por la creatinina, la urea y la glucemia, concentra la masa de probabilidad contra el extremo inferior del soporte y presenta colas derechas prolongadas. El sodio exhibe el patrón de asimetría negativa y separación en la cola izquierda. Sin embargo, es un comportamiento esperable: son marcadores acotados fisiológicamente por un extremo y sin cota práctica por el otro.

El histograma de la presión arterial no describe una densidad sino un conjunto de barras aisladas, y su gráfico cuantil-cuantil está compuesto por segmentos horizontales: todos los pacientes que comparten uno de los siete valores registrados ocupan la misma ordenada.

Estos resultados son relevantes porque el supuesto de normalidad no es un requisito accesorio de la GBN sino su fundamento: la factorización en regresiones lineales locales (2) es equivalente a la normalidad conjunta del vector. Las desviaciones observadas acotan, por tanto, el alcance de las conclusiones que pueden extraerse del modelo.

c. Estructuras elicidadas

Las tres estructuras propuestas por las personas entrevistadas se muestran en la Figura 3, junto con la obtenida por *hill-climbing*.




Fig. 3: Estructuras evaluadas. Las tres primeras corresponden a los DAGs elicitados de las personas entrevistadas; la cuarta, a la estructura aprendida de los datos mediante *hill-climbing*.

Las tres estructuras elicitadas comparten dos rasgos. En primer lugar, todas sitúan la edad como nodo raíz sin padres, coherente con su condición de variable no modificable y anterior a cualquier proceso fisiológico. En segundo lugar, todas asignan a la presión arterial un papel central: es el nodo de mayor grado en las tres. Esta coincidencia resulta notable dado que las propuestas se recabaron de forma independiente, y sugiere un consenso en la manera en que se conceptualiza el cuadro clínico de la ERC.

La estructura obtenida por *hill-climbing* contrasta radicalmente: ilustra una limitación conocida del aprendizaje estructural basado en puntuación, que el criterio recupera asociaciones, no direcciones causales.

d. Ajuste y comparación de estructuras

Se ajustó una GBN a cada una de las cuatro estructuras. El Cuadro 1 reporta el número de parámetros y las puntuaciones BIC y AIC bajo la convención (3)–(4), en la que un valor mayor indica mejor ajuste.

TABLE 1: COMPARACIÓN DE ESTRUCTURAS. EN LAS COLUMNAS BIC Y AIC (CONVENCIÓN B_{NLEARN}) UN VALOR MAYOR INDICA MEJOR AJUSTE; EN LA COLUMNA $BIC_{CLÁSICO}$, MENOR ES MEJOR.

Estructura	k	BIC	AIC
Hill-climbing	29	−8034.61	−7985.54
Especialista 3	26	−8262.63	−8218.63
Especialista 1	28	−8279.36	−8231.98
Especialista 2	26	−8280.90	−8236.91

Ambos criterios coinciden en el ordenamiento. Entre las estructuras elicitadas, la mejor es la del Especialista 3, seguida a 16.7 puntos de BIC por la del Especialista 1 y a 18.3 puntos por la del Especialista 2. Las dos últimas resultan prácticamente indistinguibles entre sí, con una diferencia de 1.5 puntos, pese a que la del Especialista 1 emplea dos parámetros más.

La estructura obtenida por *hill-climbing* supera a la mejor estructura elicitada por 228.0 puntos de BIC, una diferencia de una magnitud que en la escala habitual de interpretación resulta decisiva. Esta comparación, sin embargo, no es informativa por sí sola: dicho grafo fue seleccionado maximizando precisamente el criterio con el que se le evalúa, mientras que las estructuras elicitadas no tuvieron acceso a los datos.

e. Modelo no paramétrico

Sobre la mejor estructura identificada se sustituyó cada regresión lineal local por un estimador de Nadaraya–Watson, según (6).

El Cuadro 2 presenta la comparación nodo por nodo.



TABLE 2: COMPARACIÓN NODO POR NODO ENTRE LA ESPECIFICACIÓN LINEAL DE VARIANTE PARAMÉTRICA Y LA NO PARAMÉTRICA SOBRE EL CONJUNTO DE REFERENCIA. MAYOR ES MEJOR. LOS NODOS RAÍZ (BU, WC) SE MODELAN DE FORMA IDÉNTICA EN AMBOS ENFOQUES.

Nodo	Padres	BIC lineal	BIC no par.	AIC lineal	AIC no par.
age	bgr	−909.69	−918.20	−904.61	−905.80
bp	sc	−839.76	−847.24	−834.68	−835.55
bgr	hemo	−1247.81	−1248.36	−1242.73	−1236.92
bu	—	−1145.21	−1145.21	−1141.83	−1141.83
sc	bu	−417.92	−412.99	−412.84	−400.07
sod	bgr, sc, hemo	−699.22	−734.79	−690.75	−689.60
pot	bu	−247.43	−253.23	−242.36	−240.31
hemo	bu, sc, wc	−476.98	−507.90	−468.52	−460.18
wc	—	−2050.53	−2050.53	−2047.15	−2047.15
Total		−8034.55	−8118.45	−7985.47	−7957.40

El resultado más llamativo es que **los dos criterios no se ponen de acuerdo**. El BIC prefiere el modelo lineal por 83.9 puntos; el AIC prefiere el no paramétrico por 28.1. No es una contradicción, sino un efecto de cuánto castiga cada criterio la complejidad. El BIC descuenta varios puntos por cada parámetro adicional, mientras que el AIC descuenta solo 1. El suavizador kernel gana ajuste, pero a costa de muchos grados de libertad efectivos, y esa cantidad es suficiente para que el criterio más estricto lo rechace y el más tolerante lo acepte. En términos prácticos: si el objetivo es identificar la estructura más simple, el BIC indica que el modelo lineal basta; si el objetivo es predecir lo mejor posible, el AIC sugiere que la flexibilidad adicional vale la pena.

Bajo el BIC, un solo nodo se beneficia de la versión no paramétrica: $sc | bu$, con 4.9 puntos de ventaja. Bajo el AIC este mismo nodo sigue siendo el de mayor ganancia (12.8 puntos), y se le suman $hemo, bgr, pot$ y sod .

También es informativo ver dónde pierde el modelo no paramétrico. Los dos nodos donde más se castiga bajo BIC son justamente los que tienen tres padres: sod (−35.6 puntos) y $hemo$ (−30.9). Esto es la maldición de la dimensionalidad en acción [9]: con más predictores, el suavizador necesita muchos más grados de libertad para lograr el mismo ajuste, y la penalización se dispara.

f. Incorporación del indicador de diabetes

Para evaluar empíricamente la integración de variables categóricas se recuperó el indicador de diabetes mellitus (dm) y se ajustaron dos redes gaussianas condicionales sobre el mismo conjunto de variables y observaciones, diferenciadas únicamente por la presencia del arco $dm \rightarrow bgr$. Los resultados se muestran en el Cuadro 3.

TABLE 3: REDES GAUSSIANAS CONDICIONALES CON Y SIN EL ARCO $DM \rightarrow BGR$. MISMO CONJUNTO DE VARIABLES Y OBSERVACIONES; LA ÚNICA DIFERENCIA ES UN ARCO. MAYOR ES MEJOR.

Modelo	BIC	AIC
dm aislado	−8093.99	−8043.36
$dm \rightarrow bgr$	−8004.09	−7948.40

Lo anterior sugiere que el indicador de diabetes aporta información sustantiva sobre la glucemia que las variables continuas del modelo no capturan por sí solas.

IV. RESULTADOS Y DISCUSIÓN

a. Resultados: consultas clínicas

Las seis consultas elicítadas se evaluaron sobre la estructura de mayor puntuación, la obtenida por *Especialista 3*, mediante muestreo lógico con la función `cpquery` de `bnlearn` y 1 millón de simulaciones.

Cada pregunta se tradujo a un evento sobre las variables del modelo empleando umbrales clínicos de referencia. El Cuadro 4 resume las seis consultas, su formalización y su resultado.

TABLE 4: CONSULTAS CLÍNICAS ELICITADAS, SU FORMALIZACIÓN SOBRE EL MODELO Y SU RESOLUBILIDAD.

#	Evento	Variables requeridas	Resultado
1	$P(pot > 5.0, sod > 145 age > 60, bgr > 200)$	age, bgr, pot, sod	7.89%
2	$P(75 \leq bp \leq 85 age > 70)$	age, bp	32.05%
3	$P(ERC age \approx 0, pot \text{ bajo})$	class, age, pot	No resoluble
4	$P(ERC bp)$	class, bp	No resoluble
5	$P(ERC age \text{ alta}, bgr \text{ alta})$	class, age, bgr	No resoluble
6	$P(ERC age \text{ alta}, pot \text{ bajo}, sod \text{ bajo})$	class, age, pot, sod	No resoluble

Consultas resueltas

La consulta 1 estima la probabilidad de que un adulto mayor con hiperglucemia presente de forma simultánea potasio y sodio elevados. El resultado fue 7.89 %.

La consulta 2 estima la probabilidad de que una persona mayor de 70 años registre presión diastólica entre 75 y 85 mmHg. El resultado fue 32.05 %.

Consultas no resueltas

Las cuatro consultas restantes resultaron irresolubles, y todas por la misma causa: requieren el diagnóstico de enfermedad renal crónica (`class`), que es una variable binaria. Como se estableció en la metodología, la familia de modelos empleada admite variables discretas únicamente como padres de las continuas. Un nodo `class` que dependiera de los biomarcadores, que es la dirección que estas cuatro preguntas presuponen, no es representable. No se trata de una variable ausente por descuido, sino de una restricción de la familia de modelos.

La consulta 3 acumula además una segunda imposibilidad, independiente de la anterior. La pregunta se refiere a recién nacidos, y la edad mínima registrada en la muestra es de seis años. Aun disponiendo de la variable objetivo, evaluar el modelo en ese punto exigiría extrapolar una especificación lineal-gaussiana fuera del soporte observado, procedimiento sin validez estadística: el modelo produciría un número, pero ese número no estaría sustentado por ninguna observación.

Cabe señalar, por último, que la consulta 4 tal como fue formulada (“¿qué probabilidad hay de que la presión arterial influya en la enfermedad renal crónica?”) no constituye una consulta bien definida. La influencia de una variable sobre otra no es un evento al que pueda asignarse probabilidad dentro del modelo; sería necesario reformularla, por ejemplo, como la probabilidad de padecer ERC dado un nivel específico de presión arterial.

b. Discusión

El desenlace de las consultas constituye el hallazgo central de este trabajo. De seis preguntas formuladas por personas con formación clínica, cuatro resultaron imposibles de responder, y las cuatro fallaron por idéntico motivo: se refieren al diagnóstico. Al solicitarles preguntas de interés, la mayoría formuló aquella que en la práctica importa, que es si el paciente padece o no la enfermedad. La restricción del modelo a variables continuas dejó esa pregunta fuera de alcance.

El experimento con el indicador de diabetes precisa el diagnóstico del problema. Sería inexacto concluir que el marco simplemente “no admite variables categóricas”: la red gaussiana condicional sí las admite, y el aporte de `dm` resultó considerable. El arco `dm` → `bgr` mejoró el BIC en 89.9 puntos. El marco funciona, pero exclusivamente en una dirección: la variable discreta puede ser padre, no hijo. Y el diagnóstico de ERC es, por naturaleza clínica, una consecuencia de los biomarcadores.

Un segundo eje de discusión es la comparación entre las tres estructuras elicítadas. Se concluye que esta sí es legítima, pues ninguna de ellas se derivó de los datos. Las diferencias de 16.7 y 18.3 puntos de BIC frente a las estructuras de los Especialistas 1 y 2 respaldan de forma decisiva la propuesta del Especialista 3, mientras que la separación de 1.5 puntos entre las dos primeras las vuelve indistinguibles entre sí.

Esta lectura valida el recurso a la elicitación. Las tres estructuras convergieron de forma independiente en tratar la edad como variable exógena y la presión arterial como nodo central, decisiones que ningún algoritmo de puntuación adoptaría por sí mismo. Que las estructuras clínicas ajusten peor no las invalida: indica que codifican conocimiento que 218 observaciones sobre nueve variables no bastan para recuperar.

Persiste no obstante una discrepancia de fondo que merece atención. Los tres especialistas situaron la presión arterial como concentrador del sistema, mientras que los datos la relegan a nodo terminal con un único padre. Una explicación plausible remite a su carácter casi discreto: al tomar solo siete valores, `bp` transmite poca información estadística hacia sus supuestos hijos, y al algoritmo le resulta más rentable explicarla que emplearla para explicar.

El tercer eje son los supuestos del modelo. Las nueve variables rechazaron la normalidad. La GBN está, por tanto, mal especificada como descripción de la distribución conjunta. El experimento no paramétrico permite acotar la gravedad de ese problema. Bajo AIC, cinco de los siete nodos con padres mejoran al relajar la linealidad, lo que confirma que las relaciones no son rectas. Bajo BIC solo uno lo hace, lo que indica que con esta muestra la ganancia en ajuste rara vez compensa la complejidad añadida. El modelo lineal es incorrecto pero sencillo, y para tamaños muestrales de este orden esa combinación resulta difícil de superar.

Estas limitaciones delimitan con precisión el trabajo futuro. La línea más inmediata consiste en invertir la lógica estructural para hacer expresable el diagnóstico. Un clasificador *naive Bayes* gaussiano [10] es, en el fondo, una red bayesiana en la que la clase es el único padre de todos los biomarcadores: exactamente la dirección que el marco de las redes gaussianas condicionales sí permite. Con las mismas nueve variables ya depuradas, ese modelo permitiría responder las cuatro consultas que aquí quedaron sin respuesta. En segundo lugar, transformar logarítmicamente las variables de asimetría marcada acercaría los datos al supuesto gaussiano a bajo costo. En tercer lugar, seleccionar el ancho de banda por validación cruzada, en vez de emplear la regla de Silverman, daría al modelo no paramétrico una comparación más equitativa.



V. CONCLUSIONES

El presente trabajo utilizó redes bayesianas gaussianas para modelar las relaciones de dependencia entre nueve biomarcadores continuos asociados a la enfermedad renal crónica. Se compararon cuatro estructuras: tres elicítadas de estudiantes de medicina y una aprendida de los datos mediante *hill-climbing*.

Las tres estructuras elicítadas convergieron en dos rasgos: la edad como variable exógena y la presión arterial como nodo de mayor conectividad. La estructura aprendida contradice ambos y obtiene, pese a ello, un BIC superior por 228 puntos, al tiempo que incorpora un arco causalmente imposible. En este problema, ajuste estadístico y validez causal no coinciden, y la puntuación por sí sola no basta para elegir una estructura.

La comparación con un modelo no paramétrico mostró que las relaciones entre biomarcadores no son estrictamente lineales, pero también que con 218 observaciones la flexibilidad adicional rara vez compensa su costo en complejidad. El BIC favorece al modelo lineal; el AIC, al no paramétrico. Ninguno de los dos veredictos es erróneo: responden a objetivos distintos.

La incorporación del indicador de diabetes como variable categórica resultó factible y valiosa, con una mejora de 89.9 puntos de BIC. Sin embargo, el mismo experimento hizo visible la restricción central del marco: las variables discretas solo pueden ser padres. El diagnóstico de ERC, que es lo que cuatro de las seis consultas clínicas pedían, es una consecuencia de los biomarcadores, y por tanto no puede representarse en una red gaussiana condicional.

Esa es la conclusión de fondo. Una GBN restringida a biomarcadores continuos describe adecuadamente la estructura entre ellos, pero es un instrumento inadecuado para las preguntas que los clínicos formulan en la práctica, que giran en torno al diagnóstico. El desajuste no está en los datos ni en la estimación, sino entre la familia de modelos y el tipo de pregunta. Un clasificador *naive Bayes* gaussiano, que invierte la dirección de los arcos y coloca al diagnóstico como raíz, es la extensión más directa y queda propuesto como trabajo futuro.

El código, los datos procesados y los resultados completos están disponibles en el repositorio público del proyecto: <https://github.com/pablogzrs/ERC-gbn>.

BIBLIOGRAFÍA

- [1] Rubini, L. J., Soundarapandian, P., & Eswaran, P. (2015). *Chronic Kidney Disease* [Conjunto de datos]. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/336/chronic+kidney+disease>
- [2] Scutari, M. (2010). Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3), 1–22.
- [3] Lauritzen, S. L., & Wermuth, N. (1989). Graphical models for associations between variables, some of which are qualitative and some quantitative. *The Annals of Statistics*, 17(1), 31–57.
- [4] Nadaraya, E. A. (1964). On estimating regression. *Theory of Probability and Its Applications*, 9(1), 141–142.
- [5] Watson, G. S. (1964). Smooth regression analysis. *Sankhyā: The Indian Journal of Statistics, Series A*, 26(4), 359–372.
- [6] Silverman, B. W. (1986). *Density estimation for statistics and data analysis*. Chapman & Hall.
- [7] Hastie, T. J., & Tibshirani, R. J. (1990). *Generalized additive models*. Chapman & Hall.
- [8] Hurvich, C. M., Simonoff, J. S., & Tsai, C.-L. (1998). Smoothing parameter selection in nonparametric regression using an improved Akaike information criterion. *Journal of the Royal Statistical Society: Series B*, 60(2), 271–293.
- [9] Härdle, W. (1990). *Applied nonparametric regression*. Cambridge University Press.
- [10] Friedman, N., Geiger, D., & Goldszmidt, M. (1997). Bayesian network classifiers. *Machine Learning*, 29(2–3), 131–163.